Rapport de stage:
Arbitrages statistiques dans l'apprentissage automatique confidentiel.

Alexi Canesse, L3 informatique fondamentale,
École Normale Supérieure de Lyon
Sous la supervision d'Aurélien Garivier, Professeur,
UMPA et École Normale Supérieure de Lyon

June 21, 2022

1 Méthode des histogrammes

1.1 AboveThreshold

Répondre à de nombreuses requête est coûteux en confidentialité. Utiliser à algorithme naïf tel que le mécanisme de Laplace ne permet pas de répondre à de nombreuses requêtes avec une bonne précision tout en préservant un bon niveau de confidentialité (ε doit être petit). Dans certains cas nous ne sommes néanmoins pas intéressé par les réponses numériques, mais uniquement intéressé par le fait qu'une réponse dépasse ou non un seuil définit. Nous allons voir que `AboveThreshold` permet cela tout en ne payant que pour les requêtes qui dépassent le seuil.

```
AboveThreshold(database, queries, threshold, epsilon){
    Assert("les requêtes sont toutes de sensibilité 1");
    result = 0;
    noisyThreshold = threshold + Lap(2/epsilon);
    for(querie in queries){
        nu = Lap(4/epsilon);
        if(querie(D) + nu > noisyThreshold){
            return result;
        }
        else
            ++result;
    }
    return -1;
}
```

L'algorithme venant d'être décrit renvoie l'indice de la première requête à dépasser le seuil si une telle requête existe. C'est une version adaptée de l'algorithme initialement décrit par Dwork et Roth dans [DR14, page57]. Icelui a du sens d'un point de vue informatique mais rend le formalisme mathématiques compliqué (les auteurs eux-même tombent dans ce travers) et nous n'utiliseront pas les légers avantages de leur version.

Théorème 11:
Pour tout ensemble de requêtes $Q \in \left(\mathcal{X}^{(\mathbb{N})} \to \mathcal{T}\right)^{\mathbb{N}}$ de sensibilité 1, tout seuil $T \in \mathbb{R}$, tout $\varepsilon > 0$, $M : x \in \mathcal{X}^{(\mathbb{N})} \mapsto$ `AboveThreshold(x, Q, T, epsilon)` est *ε-differentially private.*

Démonstration[1]:
Soit $D, D' \in \mathcal{X}^{(\mathbb{N})}$ tels que $||D - D'|| \leq 1$, $Q \in \left(\mathcal{X}^{(\mathbb{N})} \to \mathcal{T}\right)^{\mathbb{N}}$ un ensemble de requêtes de sensibilité 1, $T \in \mathbb{R}$ un seuil, et $\varepsilon > 0$. On pose alors A la variable aléatoire `AboveThreshold(D, Q, T, epsilon)` et A' la variable aléatoire `AboveThreshold(D', Q, T, epsilon)`.

Soit alors $k \in \mathbb{N}$. *Montrons que* $\mathbb{P}(A = k) \leq \mathbb{P}(A' = k)$. En reprenant les notations de l'algorithme 1.1, on fixe les éléments $(\nu_i)_{i<k}$ (qui suivent une loi de Laplace de paramètre $4/\varepsilon$).

On pose alors

$$\begin{cases} g_k &= \max_{i<k} \{f_i(D) + \nu_i\} \\ g'_k &= \max_{i<k} \{f_i(D') + \nu_i\} \end{cases}$$

Ces grandeurs représente la valeur plus grande comparée au seuil bruité avant l'indice k dans le cas de l'execution sur D et de l'execution sur D'. Les probabilité qui suivent seront prisent sur

[1] La démonstration est une réécriture de celle du livre de référence [DR14, page57]. Une réécriture était nécessaire car cette démonstration présente de nombreux points limites en terme de rigueur mathématiques et de detail pas suffisant sur certains points non triviaux.

les deux variables aléatoires non fixées ν_k et $\hat{T}$ qui est la valeur du seuil bruitée. On pose enfin, pour tout $i \in \mathbb{N}$,

$$\begin{cases} y_i &= f_i(D) \\ y'_i &= f_i(D') \end{cases}$$

On note alors que, en notant l_2 la densité de la loi de Laplace de paramètre $2/\varepsilon$ et l_4 celle de paramètre $4/\varepsilon$,

$$\begin{aligned} \mathbb{P}(A = k) &= \mathbb{P}(\hat{T} \in]g_k, y_k + \nu_k]) \\ &= \int_{\mathbb{R}} \mathbb{P}(\hat{T} \in]g_k, y_k + \nu]) l_4(\nu) \mathrm{d}\nu \\ &= \int_{\mathbb{R}} \int_{g_k}^{y_k+\nu} l_2(t) l_4(\nu) \mathrm{d}t \mathrm{d}\nu \end{aligned}$$

On effectue alors un premier changement de variable affine

$$\hat{t} = t + g_k - g'_k$$

On obtient donc

$$\begin{aligned} \mathbb{P}(A = k) &= \int_{\mathbb{R}} \int_{g_k}^{y_k+\nu} l_2(\hat{t} - g_k + g'_k) l_4(\nu) \mathrm{d}t \mathrm{d}\nu \\ &= \int_{\mathbb{R}} \int_{g'_k}^{y_k+\nu-g_k+g'_k} l_2(\hat{t}) l_4(\nu) \mathrm{d}t \mathrm{d}\nu \end{aligned}$$

Il est alors temps de faire un second changement de variable affine

$$\hat{\nu} = \nu + g_k - g'_k + y'_k - y_k$$

Ainsi,

$$\begin{aligned} \mathbb{P}(A = k) &= \int_{\mathbb{R}} \int_{g'_k}^{y_k+\nu-g_k+g'_k} l_2(\hat{t}) l_4(\hat{\nu} - g_k + g'_k - y'_k + y_k) \mathrm{d}\hat{t} \mathrm{d}\nu \\ &= \int_{\mathbb{R}} \int_{g'_k}^{y_k+\nu-g_k+g'_k+g_k-g'_k+y'_k-y_k} l_2(\hat{t}) l_4(\hat{\nu}) \mathrm{d}t \mathrm{d}\nu \\ &= \int_{\mathbb{R}} \int_{g'_k}^{y'_k+\nu} l_2(\hat{t}) l_4(\hat{\nu}) \mathrm{d}t \mathrm{d}\nu \end{aligned}$$

Par définition de l_2 et l_4 nous avons donc

$$\mathbb{P}(A = k) = \int_{\mathbb{R}} \int_{g'_k}^{y'_k+\nu} \exp\left(\frac{|\hat{t}|\varepsilon}{2}\right) \exp\left(\frac{|\hat{\nu}|\varepsilon}{4}\right) \mathrm{d}t \mathrm{d}\nu$$

L'inégalité triangulaire assure alors que

$$\begin{aligned} \mathbb{P}(A = k) &\leq \int_{\mathbb{R}} \int_{g'_k}^{y'_k+\nu} \exp\left(\frac{|\hat{t} - t|\varepsilon}{2}\right) \exp\left(\frac{|t|\varepsilon}{2}\right) \exp\left(\frac{|\hat{\nu} - \nu|\varepsilon}{4}\right) \exp\left(\frac{|\nu|\varepsilon}{4}\right) \mathrm{d}t \mathrm{d}\nu \\ &= \int_{\mathbb{R}} \int_{g'_k}^{y'_k+\nu} \exp\left(\frac{|g_k - g'_k|\varepsilon}{2}\right) \exp\left(\frac{|t|\varepsilon}{2}\right) \exp\left(\frac{|g_k - g'_k + y'_k - y_k|\varepsilon}{4}\right) \exp\left(\frac{|\nu|\varepsilon}{4}\right) \mathrm{d}t \mathrm{d}\nu \end{aligned}$$

Les requêtes étant de sensibilité 1, nous avons

$$\begin{cases} 2 & \geq |g_k - g'_k| + |y'_k - y_k| \quad \geq |g_k - g'_k + y'_k - y_k| \\ 1 & = |g_k - g'_k| \end{cases}$$

Enfin, la croissance de l'intégrale assure que

$$\begin{aligned}
\mathbb{P}(A = k) &\leq \int_{\mathbb{R}} \int_{g'_k}^{y'_k+\nu} \exp\left(\frac{\varepsilon}{2}\right) \exp\left(\frac{|t|\varepsilon}{2}\right) \exp\left(\frac{\varepsilon}{2}\right) \exp\left(\frac{|\nu|\varepsilon}{4}\right) \mathrm{d}t\mathrm{d}\nu \\
&= \exp\left(\frac{2\varepsilon}{2}\right) \int_{\mathbb{R}} \int_{g'_k}^{y'_k+\nu} \exp\left(\frac{|t|\varepsilon}{2}\right) \exp\left(\frac{|\nu|\varepsilon}{4}\right) \mathrm{d}t\mathrm{d}\nu \\
&= \exp(\varepsilon) \int_{\mathbb{R}} \int_{g'_k}^{y'_k+\nu} l_2(t) l_4(\nu) \mathrm{d}t\mathrm{d}\nu \\
&= \exp(\varepsilon) \int_{\mathbb{R}} \mathbb{P}(\hat{T} \in]g'_k, y'_k + \nu]) l_4(\nu) \mathrm{d}\nu \\
&= \exp(\varepsilon)\, \mathbb{P}(\hat{T} \in]g'_k, y'_k + \nu_k]) \\
&= \exp(\varepsilon)\, \mathbb{P}(A' = k)
\end{aligned}$$

References

Dwork, Cynthia and Aaron Roth. "The Algorithmic Foundations of Differential Privacy". In: *Foundations and Trends in Theoretical Computer Science* 9 (Aug. 2014), pp. 211–407. URL: https://www.microsoft.com/en-us/research/publication/algorithmic-foundations-differential-privacy/.